LORA Low-Rank Adaptation Of LLM



1.Introduction

2. Proposed Method

3.Conclusion

4.How To Use

01 Introduction

Background

- BERT, GPT-3의 등장으로 집중되는 Transfer Learning, Fine-Tuning
 - ✓ NLP의 특징 상 training data의 부족을 해결하기 위해 Fine-Tuning을 통한 Transfer Learning Model을 활용한 Task들이 많아지고 매우 좋은 성능을 보이고 있음
 - ✓ Transfer Learning의 장점은 위처럼 성능이 좋고 다양한 Task에 활용이 가능하지만 Model의 크기가 너무 크고 무겁다는 단점이 존재함 (Parameter의 수가 너무 많음)
 - -> "Full Fine-Tuning is prohibitively expensive"
 - ✓ 이러한 문제점을 파악 후 Fine-Tuning을 일반화하기 위해 생기는 질문
 - 1. Do we need to fine-tune all the parameters?
 - 2. How expensive should the matrix updates be? (matrix rank에 대한 관점에서)
 - -> Model의 rank를 조정해서(축소해서) fine-tuning을 경량화하자

O1 Introduction Why LORA

LoRA – Low-Rank Adaptation Of LLM

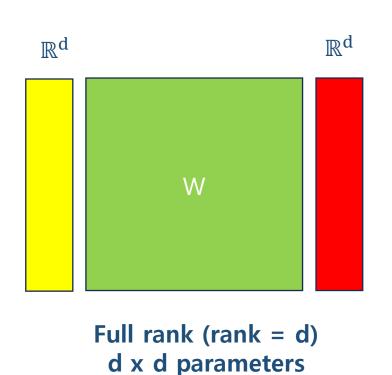
- ✓ 뜻을 해석해보자면 모델의 Rank를 조정(축소)하여 모델의 사이즈를 줄이는 method
- ✓ "It **speeds up training** and **drastically reduces the size of model checkpoints** by training few parameters compared to the base model while **preserving the performance of the full fine-tuning**"
 - -> LoRA inventor가 유튜브에서 직접 한 말
 - -> 모델의 파라미터 수를 줄이고 체크포인트 수를 줄여 모델의 크기를 줄여 학습 속도를 증가시킴과 동시에 성능을 유지함과 동시에 더 향상 시킴 (LoRA의 이점)
 - ->SO!! 어떻게 Model의 rank를 조정할 것이고 얼마나 줄일 것인가??

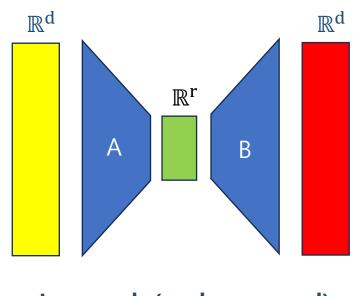
What is LoRA?

- •LoRA는 Model의 weight matrix의 rank를 경량화 하는 method
 - ✓ LoRA는 linear transformation을 통해 Full rank matrix (d x d, weight matrix)를 Low rank matrix (r x r)로 축소 시킴과 동시에 여전히 output dimension을 \mathbb{R}^d 로 유지시킴

A: dxr matrix

B: r x d matrix





Low rank (rank = r << d) 2 x d x r parameters 여기서 !당연히! 떠올라야 하는 의문점

- 1. How to choose **the low rank "r"**
- 2. How to address **the learning deficiency** from reducing the rank?

What is LoRA?

- •LoRA는 Model의 weight matrix의 rank를 경량화 하는 method
 - ✓ LoRA는 linear transformation을 통해 Full rank matrix (d x d, weight matrix)를 Low rank matrix (r x r)로 축소 시킴과 동시에 여전히 output dimension을 \mathbb{R}^d 로 유지시킴
- 기존의 full fine-tuning objective function

$$\max_{\Phi} \sum_{(x,y)\in\mathcal{Z}} \sum_{t=1}^{|y|} \log \left(P_{\Phi}(y_t|x, y_{< t}) \right)$$

- LoRA를 통해 경량화 한 adaptive fine-tuning objective function

$$\max_{\Theta} \sum_{(x,y)\in\mathcal{Z}} \sum_{t=1}^{N} \log \left(p_{\Phi_0 + \Delta\Phi(\Theta)}(y_t | x, y_{< t}) \right)$$

이때, |⊙| ≪ |Φ| 임

→ 이러한 가정을 통해 모델을 경량화 및 최적화 속도를 빠르게 함

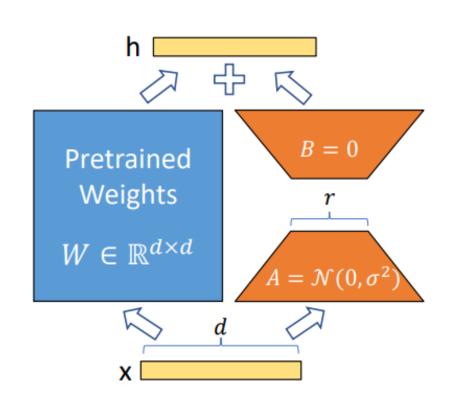
What is LoRA?

• LoRA에서의 h 수식

✓ Adaptive optimzier인 LoRA가 최종적으로 만들어내는 h를 살펴보자

$$h = W_0 x + \Delta W x = W_0 x + BA x$$

✓ 이때, W_0 는 pre-trained weight matrix, Δ W는 LoRA에서 연산되는 새로운 weight matrix (BA, where B ∈ $\mathbb{R}^{d \times r}$, A ∈ $\mathbb{R}^{r \times d}$, BA ∈ $\mathbb{R}^{d \times d}$)



How to choose the low rank "r"

- 앞에서 본 것처럼 r의 크기는 매우 중요
 - $\checkmark \Delta Wx$ scaled by $\frac{\alpha}{r}$, where α is a constant in r
 - -> Optimizing with Adam, tuning α is roughly the same s tuning the learning rate simply set α to the first r (we try and do not tune it)
 - ✓ 즉, Adam의 Ir 최적화 방식과 비슷하게 r의 크기를 최적화 함

How to address the learning deficiency from reducing the rank?

• 다양한 LoRA Experiment

- ✔ RoBERTa_base, RoBERTa_large, DeBERTa_XXL, GPT-2 M, GPT-2 L, GPT-3을 여러가지 adapter tuning, FT(Fine-Tuning), BitFit 등 많은 방식들과 비교해봤지만 LoRA가 Trainable Parameters 수를 현저히 많이 줄임과 동시에 성능이 많이 저하되지 않고 오히려 더 좋은 성능을 보였음
 - -> LoRA는 rank reductio을 활용하여 경량화 하였지만, 경량화 과정에서 성능이 저하되지는 않았음

Benefits of using LoRA

Reduction of checkpoints sizes

- ✓ LoRA leads to smaller checkpoints
- ✓ Ex) Full-finetuning: 175,000,000,000 trainable parameters, 1TB / checkpoint LoRA: 4,700,000 trainable parameters, 25MB / checkpoint

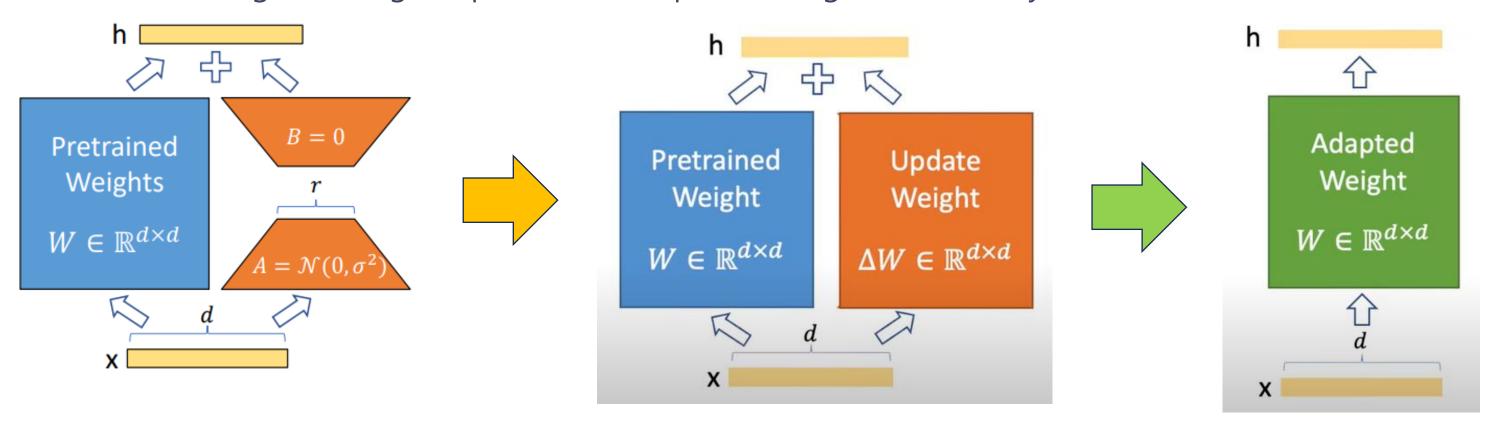
Doesn't introduce any inference latency

- ✓ LoRA add additional weight to pretrained weights(Original parameters)
- ✓ Final Adapted Weight = Pretrained Weight(Original parameters) + Update Weight(Generated by LoRA, Reduction of the matrix $(r \times d)$)
 - -> At this moment, There is "NO additional latency" because of the LoRA's simplicity (+ by parallel)
 - -> Simply just subtracting the updates, We can get original parameters

Benefits of using LoRA

Adapted Weight

- ✓ Adapted Weight = Pretrained Weight+ Update Weight
- ✓ Pretrained Weight = Original parameters, Update Weight = made by LoRA



LoRA를 정리하자면, Transfer Learning에서 Fully Fine-Tuning을 거치지 않고 Original parameters에 Update Weight을 더해줌으로써 Pretrained model을 Low rank Fine-Tuning하는 method

Conclusion

Simplification of fine-tuning

- •LoRA는 Transfer Learning & Fine-Tuning을 문제점인 너무 많은 파라미터 및 너무 큰 모델의 크기를 Low Rank Fine-Tuning으로 해결한 method
 - ✓ 최근의 NLP 동향은 The Bigger, The Better의 동향임을 고려하였을 때, Fine-Tuning의 경량화는 매우 중요 하고 유익한 Task임을 알 수 있음
 - -> LLM을 효율적으로 튜닝할 수 있음
 - ✓ 다른 Adapter류의 기법과 다르게 Additional latency가 발생하지 않음
 - ✓ LoRA는 대부분의 dense layer에 적용 가능함

How to use LoRA in python

- Installation
 - ✓ LoRA installation
- Usage
 - ✓ How to use LoRA
- Model Architecture
 - ✓ Model Arch with LoRA
- Training
 - ✓ How to fine-tuning with LoRA

Reference: https://github.com/fshnkarimi/Fine-tuning-an-LLM-using-LoRA

Installation_library

Installation

```
✓ !pip install datasets
   !pip install transformers
   !pip install peft
   !pip install evaluate
   from datasets import load_dataset, DatasetDict, Dataset
   from transformers import (
      AutoTokenizer,
      AutoConfig,
      AutoModelForSequenceClassification,
      DataCollatorWithPadding,
      TrainingArguments,
      Trainer)
   from peft import PeftModel, PeftConfig, get_peft_model, LoraConfig
   import evaluate
   import torch
   import numpy as np
```

Usage

Usage

- ✓ Load your dataset
- ✓ Define the LoRA model architecture
 - -> Define backbone model
 - ex) GPT- neo 1.3b, Roberta-base, ...
- ✓ Tokenize the dataset
- ✓ Train the LoRA model

Reference: https://huggingface.co/docs/peft/quicktour

Usage

Usage

✓ Train the LoRA model

First, What is **PEFT (Parameter-Efficient Fine-Tuning)**

- -> PEFT : Reducing LLM Fine Tuning cost
- -> To Use PeftModel we have to define PeftConfig that stores all the important parameters for

building PeftModel

Second, Define **LoraConfig** (= PeftConfig)

- 1. task_type: the task to train for (ex, sequence-to-sequence language modeling)
- 2. inference_mode: whether you're using the model for inference or not
- 3. r: the dimension of the low-rank matrices
- 4. lora_alpha: the scaling factor for the low-rank matrices
- 5. lora_dropout: the dropout probability of the LoRA layers

Usage

LoRA Config in python

Usage

Training Peft Model

✓ We can use Transformers Trainer, Accelerate, or any custom Pytorch training loop

```
Ex)
training_args = TrainingArguments(
      output_dir="your-name/bigscience/mt0-large-lora", -> backbone model 디렉토리
learning_rate=1e-3,
      per_device_train_batch_size=32,
      per_device_eval_batch_size=32,
      num_train_epochs=2,
      weight_decay=0.01,
      evaluation_strategy="epoch",
      save_strategy="epoch",
      load_best_model_at_end=True,
```

Usage

Training Peft Model

✓ Pass final model, training arguments, dataset, tokenizer, and any other necessary component to Trainer

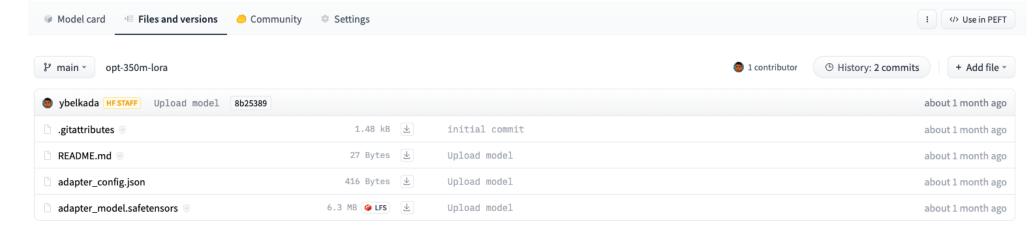
```
Ex)
trainer = Trainer(
         model=model,
         args=training_args,
         train_dataset=tokenized_datasets["train"],
         eval_dataset=tokenized_datasets["test"],
         tokenizer=tokenizer,
         data_collator=data_collator,
         compute_metrics=compute_metrics,
trainer.train()
```

Usage

- Save model
 - ✓ model.save_pretrained("output_dir")
 - -> Fine-Tuning 된 Model 저장
- Save model to the Hub
 - ✓ from huggingface_hub import notebook_login

notebook_login()

model.push_to_hub("your-name/bigscience/mt0-large-lora")



-> HuggingFace Hub에 업로드 된 Fine-Tuning된 Model

Q & A The litter